

ЛИТЕРАТУРНЫЙ ОБЗОР

Московский физико-технический институт
Физтех-школа прикладной математики и информатики
Кафедра когнитивных технологий

Исследование функций потерь и свойств нейросетевых метрик сравнения изображений для tone mapping задач

Студент:

Алчымбаев Атахан

Научный руководитель: Тимофеев Валерий Андреевич

Актуальность задачи

Динамический диапазон нашей обычной жизни может превышать 120 дБ, однако камеры смартфонов и обычные цифровые камеры могут захватывать динамический диапазон только 90 дБ, что иногда приводит к потере деталей изображения. В настоящее время некоторые профессиональные аппаратные приложения и алгоритмы объединения изображений были разработаны для работы с широким динамическим диапазоном (WDR*), но, к сожалению, существующие устройства не могут отображать изображение WDR.

* wide dynamic range (WDR), high dynamic range (HDR) – синонимы

Актуальность задачи

Отображение тона (TM), таким образом, становится важным шагом для демонстрации изображения WDR на наших обычных экранах, которые преобразуют изображение WDR в изображение с низким динамическим диапазоном (LDR). Все больше и больше исследователи сосредоточены на этой теме и прилагают все усилия для разработки превосходного оператора отображения тона (ТМО), который показывает детализированные изображения, какими мы видим нашими человеческими глазами.

Tone mapping

Tone mapping(TM) – это метод, используемый в обработке изображений и компьютерной графике для сопоставления одного набора цветов с другим, чтобы в среднем приблизить внешний вид изображений с высоким динамическим диапазоном(HDR) к более ограниченному динамическому диапазону(LDR) [0]

Формулировка задачи tone mapping

В основе алгоритма тон-мэппинга лежит tone-curve (кривая тона) – ф-я отображения из одной области в другую (ТМО). ТМО могут быть следующими:

- M: HDR input L из R^+ → значение пикселей I из $\{0, \dots, 255\}$

L может быть в произвольных единицах, но для большинства алгоритмов отображения тона ожидается, что он будет линейно связан со значениями яркости.

Формулировка задачи tone mapping

- V : HDR input L из R^+ → более сжатое T из R^+

После этого применяется модель отображения, чтобы преобразовать их в пиксельные значения – должно быть дополнено окончательным преобразованием в отображаемое значение I из $\{0, \dots, 255\}$ (чтобы можно было отобразить результат на дисплее) [2]

Схема решения задачи

- input: HDR image
- output: LDR image

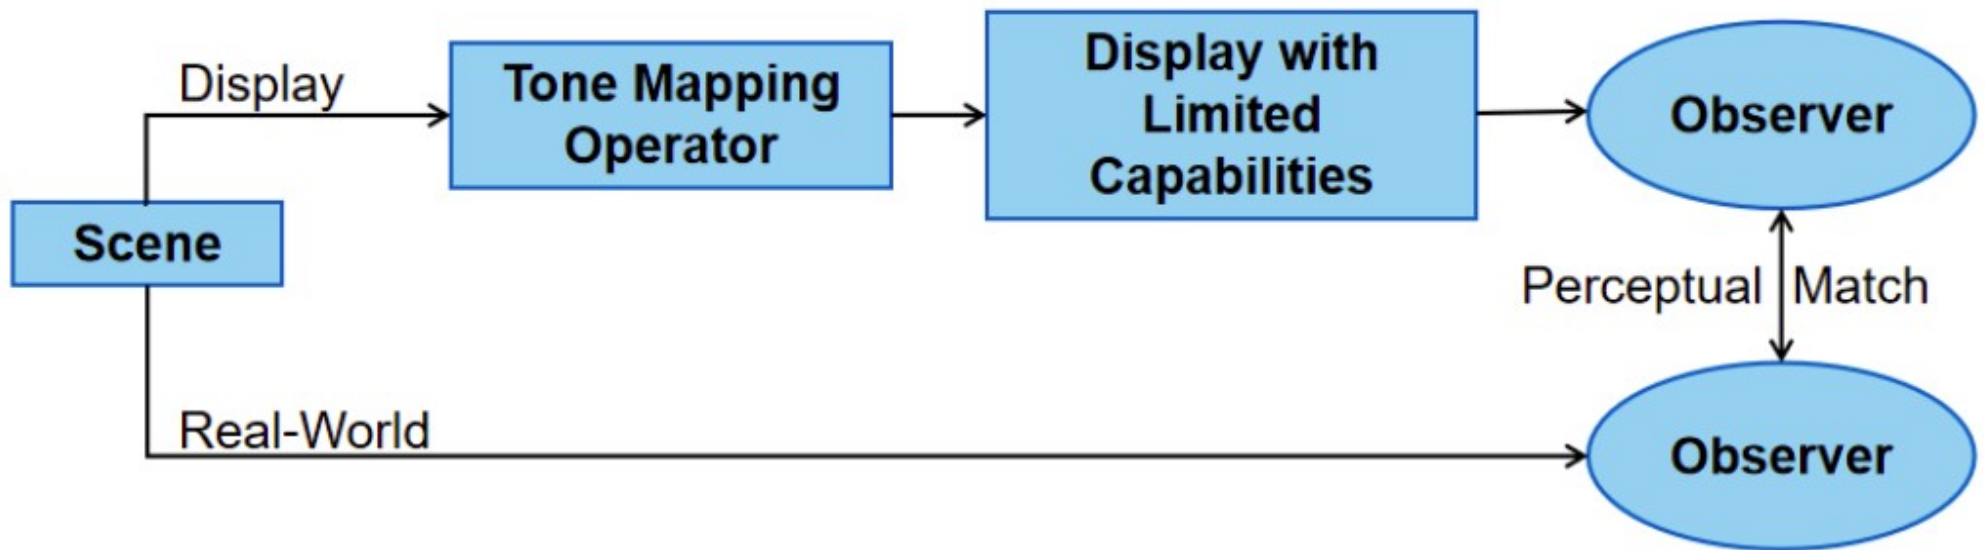
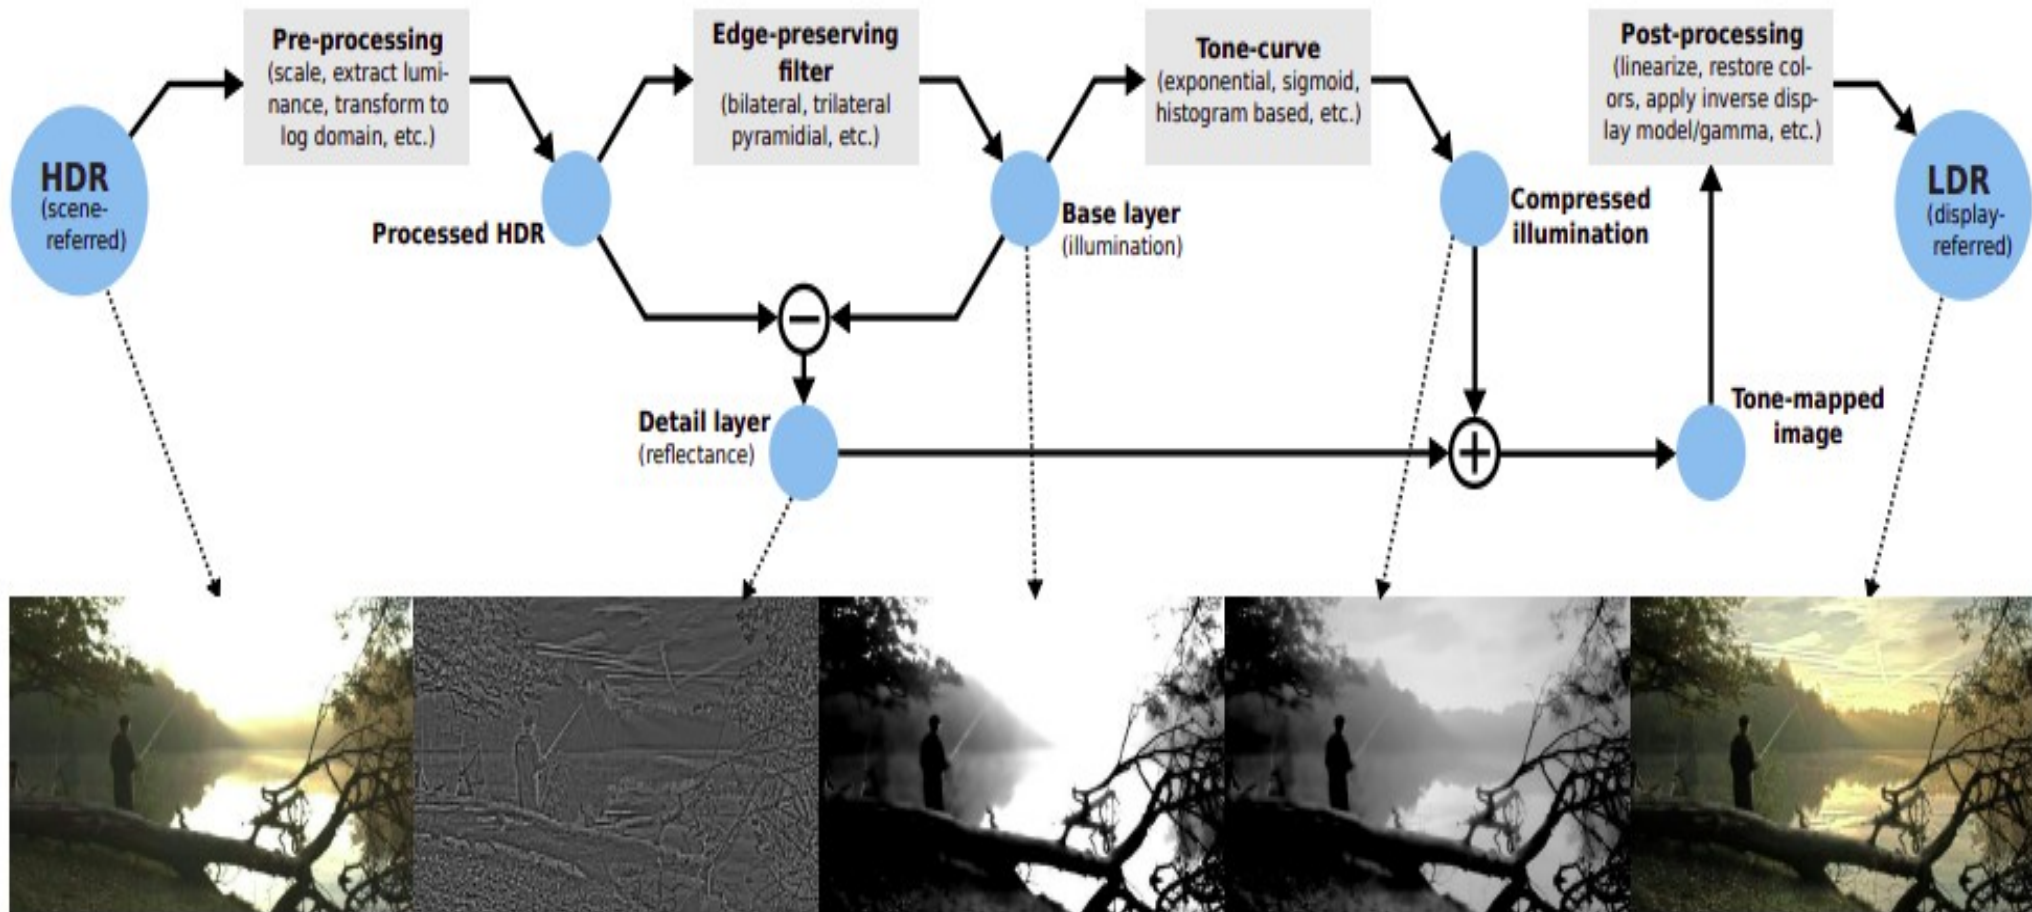


Fig. 1: Ideal tone mapping process

Пайплайн для local tone mapping



Картинка взята из статьи [2] A comparative review of tone-mapping algorithms for high dynamic range video - 2017

Классификация алгоритмов ТМ

Существует несколько классификаций.
Будем придерживаться следующей из статьи [1]:

- традиционные
 - глобальные
 - локальные
- основанные на машинном обучении

Global TM

Во всех global TM функция отображения выбирается один раз для каждой обработанной сцены на основе ее характеристик, таких как яркость. Он применяется ко всем пикселям изображения независимо от значений в окружающих пикселях [13].

Global TM

- Ward's TM [1]

Вычислительно эффективен, поскольку он просто применяет определенный коэффициент масштабирования к входным изображениям и отображает результирующие выходные данные, но приводит к потере видимости вследствие отсечения самых высоких и самых низких значений пикселей

Global TM

- Ferwerda's TM [1]

Эта модель очень важна из-за экспериментов, охватывающих визуальное поле за счет обеспечения иммерсивной системы (это с-мы, обеспечивающие эффект полного или частичного присутствия в альтернативном пространстве) отображения до такой, что визуальное состояние зрителя может быть определено на всем дисплее, но это не полностью отражает ранние стадии визуальной адаптации

Global TM

- A histogram adjustment TMO [1]

Этот метод показывает более полное воспроизведение контраста, чем другие, в то же время он может гарантировать, что контрастность результирующего изображения не превышает восприятие рецептора. Это также позволяет избежать проблемы отсечения одиночных методов адаптации(single adaptation methods). Несмотря на это, он по-прежнему страдает от потери информации.

Local TM

- В local TMO, чтобы сжать область яркости в отображаемый диапазон, сначала она отображается с помощью функции global TM. После этого, чтобы улучшить качество, выполняется локальная адаптация. Эта адаптация обеспечивает различную экспозицию для каждой части входного изображения [13].

Local TM

- Schlick's quantization technique (метод квантования Шлика) [1], [4]:
 - логарифмическое отображение – выдает плохой результат
 - экспоненциальное отображение – выдает плохой результат
 - третий метод имеет рациональную кривую отображения с асимметричной формой, обрабатывая верхние и нижние пиксели взаимно, обеспечивает более гладкие результаты. Он также внедрил подход к обработке цвета – Schlick's color correction [4]

[1] A review for Tone-mapping Operators on Wide Dynamic Range Image - 2021

[4] Color Correction for Tone Mapping - 2009

Local TM

- Durand's TMO [1]

Декомпозиция входного HDR изображения на два отдельных слоя: базовый слой и слой деталей, используя нелинейный фильтр с сохранением краев, известный как двусторонний фильтр. Контрастность базового слоя уменьшается при сохранении деталей в детальном слое. Слой деталей подчеркивает мелкие детали. Чтобы ускорить процесс декомпозиции, они применяются две стратегии:

Local TM

кусочно-линейная аппроксимация в области интенсивности и субдискретизация в пространственной области. Наконец, tone mapped HDR может быть получен путем объединения обработанных двух слоев. Это устраняет артефакты ореола, которые происходят в методе Шлика, но иногда это чрезмерно усиливает локальные детали изображения, из-за чего теряется реалистичность

Local TM

- Jie's TMO [1]

Входные данные HDR разбиваются на блоки $m \times n$, затем выполняются операции \min и \max для каждого блока, получая две матрицы (M_{\max} и M_{\min}). После билинейной интерполяции матрицы расширяются до того же размера, что и входное изображение WDR. Использование логарифмической функции и метода интерполяции позволяет учитывать соседние пиксели, в полной мере используя локальную информацию. Этот метод позволяет получать более яркие изображения и является энергоэффективным.

MACHINE LEARNING-BASED TMO

- Patel [1]

GAN, который учится сопоставлять яркость реального мира с яркостью на выходе. Этот оператор учится у многих распространенных TMO создавать визуально приятные изображения, из-за чего производительность не будет значительно превышать эти TMO

MACHINE LEARNING-BASED TM

- Montulet [1]

Используется GAN для улучшения изображения при слабом освещении, применив глубокую сверточную генеративную состязательную сеть (DCGAN) к каналу яркости вместо непосредственного использования цветowych компонентов, чтобы избежать смещения цвета. Метод Montulet основан на традиционных методах TM для генерации целевых изображений LDR, поэтому их поведение не будет заметно отличаться от поведения традиционного метода TM

MACHINE LEARNING-BASED TMO

- Rana [1]

Этот ТМО мог бы обслуживать обширный сценический контент (например, помещения, открытые площадки, ландшафты, структуры, людей и т.д.). И решать проблемы (например, насыщенность, размытие рисунка, мозаичные узоры), вызванные традиционными Gan-based ТМО. Но когда входные изображения имеют размер, отличный от обучающего изображения, возможно, это приведет к появлению артефактов.

MACHINE LEARNING-BASED TM

- Su [1]

Мультимодальный метод отображения тона, состоящий из двух сетей, называемых EdgePreservingNet и ToneCompressingNet. EdgePreservingNet обучена фильтровать входные изображения WDR, сохраняя высокочастотную информацию в изображении. Изображения WDR разделены на детальный и базовый слои. Слой детализации улучшен в результате функции tan для получения изображений LDR более высокого качества, в то время как базовый слой сжимается с помощью сетки ToneCompressingNet.

MACHINE LEARNING-BASED TM

В конечном счете, слой улучшенной детализации и сжатый базовый слой объединяются в конечный результат LDR в оттенках серого. С помощью цветокоррекции создается окончательное красочное HDR-изображение с отображением ТОНОВ.

MACHINE LEARNING-BASED TMO

- Kim [1]

Он предложил ТМО для рентгеновских изображений

MACHINE LEARNING-BASED TM

- SOTA methods: CURL, HDRNet, CSRNet, Pix2Pix и Zero-DCE.

Далее рассмотрим каждый из методов
немного подробнее

MACHINE LEARNING-BASED TM

- CURL [6]

CURL – новый нейронный блок для улучшения изображения. CURL черпает вдохновение у художников/фотографов и ретуширует изображения на основе глобальных кривых настройки изображения. Кривые ретуши автоматически обучаются для настройки свойств изображения путем использования представления изображения в трех различных цветовых пространствах (CIE Lab, HSV, RGB).

MACHINE LEARNING-BASED TM

Корректировки, применяемые этими кривыми, смягчаются новой функцией потерь многоцветного пространства. В экспериментальной оценке encoder/decoder backbone, дополненный подключаемым блоком CURL, показал высокие результаты.

MACHINE LEARNING-BASED TM

- HDRNet [7]

Архитектура нейронной сети, которая может выполнять улучшение изображения в режиме реального времени на изображениях с полным разрешением, сохраняя при этом высокочастотные эффекты. Модель обучается с использованием пар входных/выходных изображений, что позволяет ей обучаться из эталонной реализации некоторого алгоритма или из настроек человека.

MACHINE LEARNING-BASED TM

Выполняя большую часть вычислений в рамках двусторонней сетки(bilateral grid) и прогнозируя локальные аффинные цветовые преобразования, модель способна обеспечить правильный баланс между выразительностью/экспрессивностью (expressivity) и скоростью. Для построения этой модели были введены два новых уровня: поиск, зависящий от данных, который позволяет выполнять нарезку в двусторонней сетке, и мультипликативная операция для аффинного преобразования.

MACHINE LEARNING-BASED TM

Благодаря сквозному обучению и оптимизации нашей функции потерь при полном разрешении (несмотря на то, что большая часть сети имеет сильно уменьшенное разрешение), модель способна изучать эффекты с полным разрешением и не зависящие от масштаба.

MACHINE LEARNING-BASED TM

- CSRNet [8]

Ретушь фотографий направлена на повышение эстетического визуального качества изображений, которые страдают от фотографических дефектов, таких как чрезмерная/недостаточная экспозиция, плохой контраст, негармоничная насыщенность. Практически ретушь фотографий может быть выполнена с помощью ряда операций обработки изображений. Исследовав некоторые часто используемые операции ретуширования, математически найдено, что эти независимые от пикселей операции могут быть

MACHINE LEARNING-BASED TM

аппроксимированы или сформулированы с помощью многослойных перцептронов (MLP). На основе этого анализа предложена чрезвычайно легкая структура - сеть условной последовательной ретуши (CSRNet) - для эффективной глобальной ретуши изображений. Сеть CSRNet состоит из базовой сети и сети условий. Базовая сеть действует как MLP, который обрабатывает каждый пиксель независимо, а сеть условий извлекает глобальные объекты входного изображения для генерации вектора условий.

MACHINE LEARNING-BASED TM

Чтобы реализовать операции ретуширования, модулируются промежуточные объекты с помощью Global Feature Modulation (GFM), параметры которой преобразуются вектором условий. Благодаря использованию свертки 1×1 , CSRNet содержит менее 37 тыс. обучаемых параметров, что на порядки меньше, чем существующие методы, основанные на обучении.

MACHINE LEARNING-BASED TM

- Pix2Pix [9]

Условные состязательные сети как универсальное решение проблем перевода изображения в изображение – эти сети не только обучаются мэппингу из входного в выходное изображение, но также обучают функцию потерь для обучения этому отображению. Это позволяет применять один и тот же общий подход к проблемам, которые традиционно требовали бы очень разные функции потерь. Этот подход эффективен при синтезе фотографий из карт меток, восстановлении объектов из карт краев и

MACHINE LEARNING-BASED TM

раскрашивании изображений. Действительно, с момента выпуска программного обеспечения `pix2pix`, большое количество пользователей Интернета (многие из них художники) опубликовали свои собственные эксперименты с нашей системой, далее демонстрируя его широкую применимость и простоту внедрения без необходимости настройки параметров.

MACHINE LEARNING-BASED TM

- Zero-DCE [10]

Новый метод – Zero-Reference Deep Curve Estimation, который формулирует улучшение освещенности как задачу оценки кривой для конкретного изображения с помощью глубокой сети. Метод обучает легкую глубокую сеть, DCE-Net, для оценки попиксельных кривых и кривых высокого порядка для настройки динамического диапазона данного изображения. Оценка кривой специально разработана с учетом диапазона значений пикселей, монотонности и дифференцируемости.

MACHINE LEARNING-BASED TM

Zero-DCE привлекателен тем, что он не требует каких-либо парных или непарных данных во время обучения. Это достигается за счет набора тщательно сформулированных non-reference loss functions (unsupervised learning), которые неявно измеряют качество улучшения и управляют обучением сети. Этот метод эффективен, поскольку улучшение изображения может быть достигнуто с помощью интуитивно понятного и простого отображения нелинейных кривых. Несмотря на его простоту, он хорошо подходит для различных условий освещения.

MACHINE LEARNING-BASED TM

- LTMNet [3]

Размер первого слоя $512 \times 512 \times 4$, за ним следует последовательность сверточных слоев с функцией активации Relu и Max pooling-и. Размер последнего слоя пулинга регулируется так, чтобы размер выхода соответствовал размеру кривых $M \times N \times C$ - высота, ширина сетки участков изображений и количество каналов соответственно. Нет ограниченности в разрешении изображения и явно сопоставляет каждую кривую с локальной областью.

MACHINE LEARNING-BASED TM

Однако, обычно CNN уступают GAN из-за ограничений – результат выходного изображения CNN сильно зависит от выбора функции потерь (одним из решений этой проблемы являются GAN). Но все же в [3] приводится обоснованный выбор функции потерь (далее будут представлены результаты сравнения LTMNet и SOTA методов).

Датасеты

- MIT-Adobe FiveK *

5000 сцен, сделанных SLR камерами. Все они находятся в формате RAW, то есть сохраняется вся информация, записанная датчиком камеры. Каждый из 5 экспертов отретушировал по 5000 фото (итого 30000 фото). Входные файлы доступны в формате DNG; пять выходных файлов доступны в формате TIFF

* Ссылка на датасет: <https://data.csail.mit.edu/graphics/fivek/>

Датасеты

- HDR+ Burst Photography *

Набор данных HDR+ состоит из 3640 серий изображений, которые в общей сложности составляют 28 461 изображение. Серии содержат от 2 до 10 raw фотографий каждый. Каждая серия обрабатывается в объединенное, выровненное и улучшенное изображение с высоким динамическим диапазоном (HDR) на выходе. Для получения результатов предоставляется как промежуточный результат выравнивания и слияния кадров (в формате DNG), так и конечный результат конвейера (в формате JPG).

* Ссылка на датасет: <http://www.hdrplusdata.org/dataset.html>

Датасеты

Существует множество других датасетов:

- LTM dataset
- HDR Survey dataset
- HDRI Haven dataset
- DIV2k dataset
- DeepTMO's dataset
- и др

Метрики

Известные методы оценки в задачах tone mapping:

- PSNR
- SSIM
- LPIPS
- TMQI
- BTMQI
- PixFID
- и др

Сравнение методов

Больше визуальных сравнений LTMNet и SOTA методов в статье [3]

Input



CURL



HDRNet



CSRNet



Pix2Pix



Zero-DCE



LTMNet



Ground truth



Сравнение методов

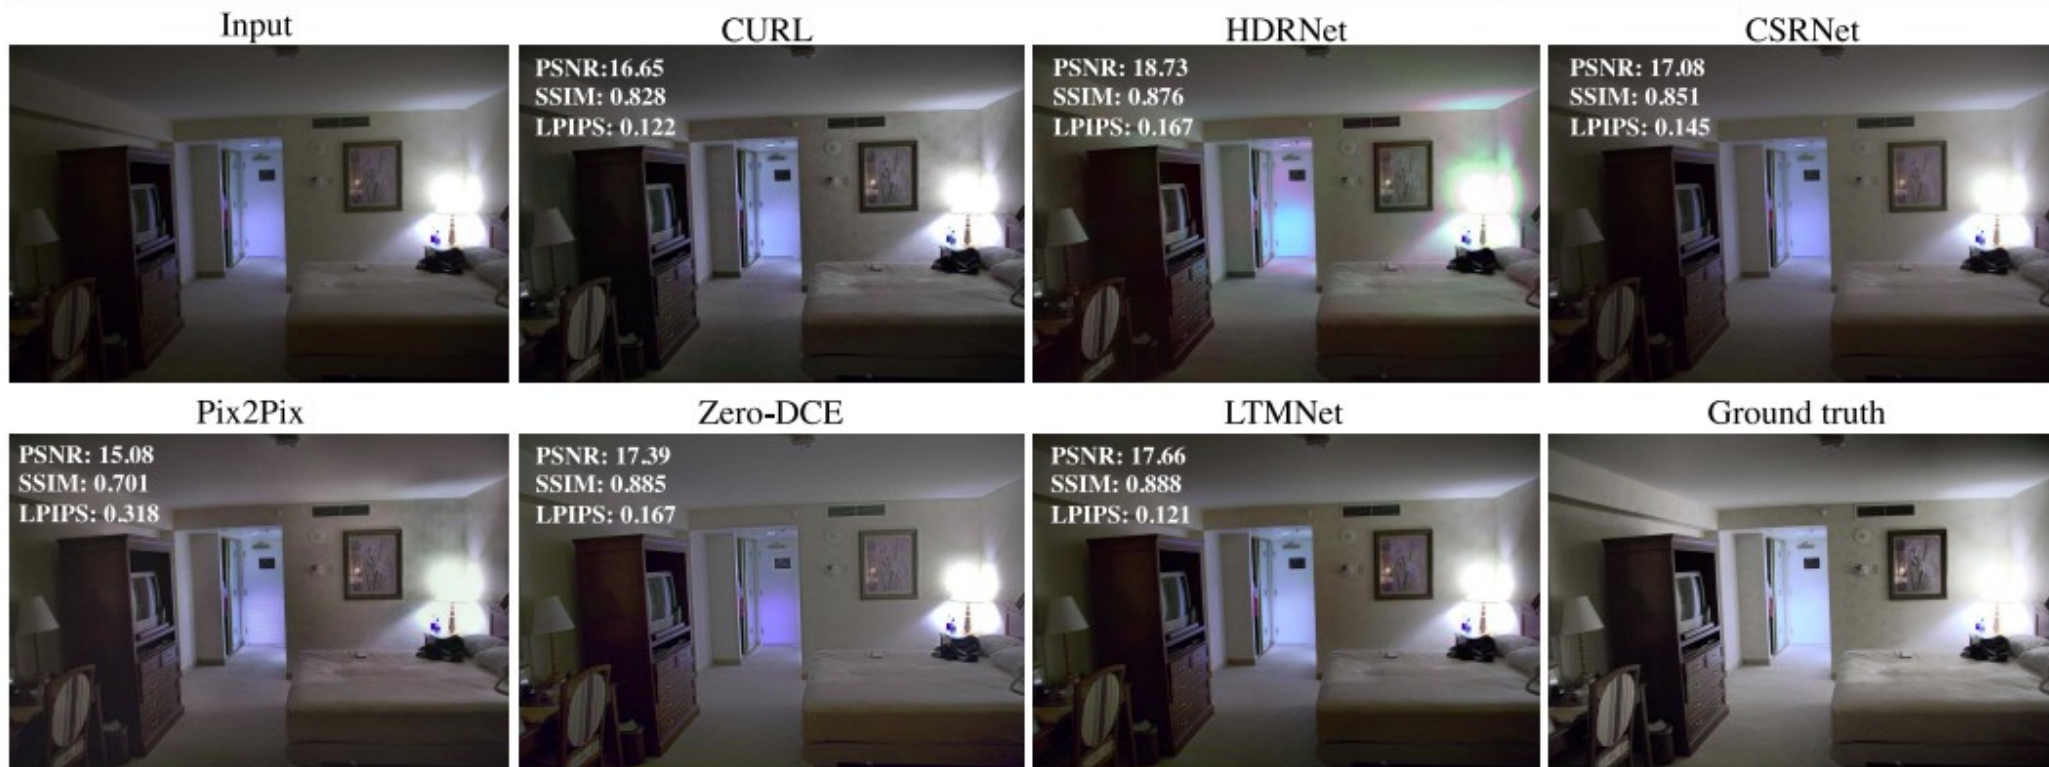


FIGURE 8. Visual comparison of our LTMNet against SOTA methods: CURL [2], HDRNet [25], CSRNet [1], Pix2Pix [64], and Zero-DCE [48], on our LTM dataset. Our LTMNet produces visually enhanced results while avoiding structural and color artifacts.

Сравнение методов

TABLE 1. Quantitative comparison between our method and SOTA methods on our LTM dataset and HDR+ dataset. \downarrow means smaller values indicate better performance and vice versa.

Dataset	Method	PSNR \uparrow	SSIM \uparrow	LPIPS \downarrow
LTM	CURL [2]	26.46	0.934	0.063
	Zero-DCE [48]	21.13	0.898	0.109
	HDRNet [25]	25.75	0.946	0.075
	CSRNet [1]	26.31	0.943	0.059
	Pix2Pix [64]	22.00	0.784	0.198
	LTMNet (ours)	27.00	0.953	0.058
HDR+	CURL [2]	25.32	0.878	0.098
	Zero-DCE [48]	16.35	0.677	0.285
	HDRNet [25]	26.90	0.892	0.082
	CSRNet [1]	26.13	0.877	0.101
	Pix2Pix [64]	22.85	0.791	0.207
	LTMNet (ours)	24.76	0.876	0.099
	LTMNet + Res. (ours)	25.20	0.893	0.080

TABLE 2. Ablation studies for grid size on the LTM dataset.

Grid Size	PSNR \uparrow	SSIM \uparrow	LPIPS \downarrow
1 \times 1	26.39	0.937	0.070
2 \times 2	26.93	0.947	0.064
4 \times 4	26.97	0.951	0.062
8 \times 8	27.00	0.953	0.058
16 \times 16	26.81	0.952	0.058

TABLE 3. Results for global vs. local tone mapping on the MIT-Adobe FiveK dataset.

Model	PSNR \uparrow	SSIM \uparrow	LPIPS \downarrow
LTM	22.55	0.903	0.071
GTM+LTM	23.85	0.902	0.076
GTM	24.27	0.913	0.068

TABLE 4. Quantitative comparison between our method (LTMNet) and SOTA methods on the MIT-Adobe FiveK dataset.

Method	PSNR \uparrow	SSIM \uparrow	LPIPS \downarrow
CURL [2]	24.19	0.892	0.079
DeepUPE [42]	23.40	0.875	0.093
CSRNet [1]	23.64	0.906	0.069
Zero-DCE [48]	16.85	0.796	0.202
LTMNet (grid 1x1)	24.27	0.913	0.068
LTMNet (grid 8x8)	22.55	0.903	0.071

Субъективная оценка качества

Пример эксперимента из статьи [12].

В [12] было проведено субъективное попарное сравнение, чтобы подтвердить воспринимаемое качество tone-mapped изображений. В этом субъективном исследовании приняли участие 20 человек в возрасте от 23 до 38 лет с нормальным или скорректированным до нормального зрением.

Субъективная оценка качества

- Тестовая среда и установка:

Тесты проводились в помещении, предназначенном для профессиональных субъективных тестов, с условиями окружающего освещения. Dell UltraSharp 24 Monitor (DELL U2415) использовался для отображения изображений с разрешением экрана 1920×1200 при частоте 59 Гц. Фоновому окну рабочего стола было присвоено значение 128 gray value. Каждый stimuli включал пару tone mapped изображений для данной сцены, где каждая пара всегда состояла из изображения, полученного

Субъективная оценка качества

рассматриваемым алгоритмом, и другого, полученного с использованием наиболее эффективных tone mapping функций на основе TMQI rankings. Чтобы удовлетворить широкий спектр контента было выбрано 15 сцен из 105 изображений тестового набора, представляющих 5 различных категорий (по 3 сцены на категорию), а именно:

- i) Humans, ii) Dark/Noisy, iii) Indoor,
- iv) Structures, v) Landscapes.

Субъективная оценка качества

- Процедуры:

Был проведен попарный субъективный эксперимент, в котором наблюдателя попросили выбрать изображение, показав пару изображений вместе. Опция одинаковости не была включена, чтобы заставить пользователей выбирать один из stimuli. Каждому участнику было предложено выбрать изображение, которое является более реалистичным и привлекательным для него. Участникам было предоставлено неограниченное время для принятия решения и записи своего выбора.

Субъективная оценка качества

Эксперимент был разделен на тренировочную и тестовую сессии, где обучение включало в себя инструктаж каждого участника для ознакомления с задачей субъективной оценки качества. Каждый наблюдатель дважды сравнивал пару изображений, причем каждое tone-mapped изображение отображалось с обеих сторон (e.g., OurTMO vs. first-best tone mapped и first-best tone mapped vs. OurTMO)

Субъективная оценка качества*

- Результаты:

Чтобы количественно оценить результаты попарных субъективных тестов, были масштабированы выигрышные частоты модели до непрерывных показателей качества, используя широко известную модель Брэдли Терри (BT). Масштабирование выполняется с использованием статистического анализа, чтобы определить, является ли воспринимаемая разница в визуальном качестве сравниваемых моделей статистически значимой.

Субъективная оценка качества

Вероятность предпочтения для нашего метода
 $\text{Pref} - \text{Prob_}(\text{DeerTMO})$ математически задается
как:

$$\text{Pref} - \text{Prob_}(\text{OurTMO}) = w_ \text{OurTMO} / N + t/(2*N),$$

где $w_ \text{OurTMO}$ - частота выигрышей
предложенной нами модели; t - временная
частота; N - общее количество участников.

Статистическая модель основана на гипотезе о
том, что каждое сравниваемое ТМО в попарном
тесте имеет равную вероятность возникновения,
т.е. 0,5, и, следовательно, следует

Субъективная оценка качества

биномиальном распределении. Основываясь на первоначальной гипотезе, на собранных данных был проведен биномиальный тест, и критические пороговые значения были получены путем построения кумулятивной функции биномиального распределения. Установив 95% в качестве уровня значимости, если мы получим 13 ($B(13, 20, 0.5) = 0.9423$) или больше голосов за предложенный нами метод, мы считаем, что наше tone-mapped изображение значительно улучшилось с точки зрения субъективного качества.

Субъективная оценка качества*

Аналогично, установив 5% в качестве уровня значимости, если мы получим 6 ($B(6, 20, 0.5) = 0.0577$) или меньше голосов за предложенный нами метод, мы считаем, что наше tone-mapped изображение наименее предпочтительно с точки зрения субъективного качества.

* В случае проведения такого эксперимента на лабе тема НИР дополнится на:
Текущая_тема_НИР + “на основе экспериментальных данных о зрительной системе человека”

Colour correction

В пайплайне обработки изображения для улучшения его качества до tone mapping'a находится colour correction.

- Цветокоррекция - это проблема сопоставления откликов сенсора, измеренных камерой, с RGBs, закодированными на дисплее, или со стандартным цветовым пространством, таким как CIE XYZ.

При коррекции цвета на основе регрессии RAW RGBs камеры отображаются в соответствии с простой формулой (например, линейное отображение).

Colour correction

Методы регрессии включают методы наименьших квадратов, полиномиальные и корневые полиномиальные подходы.

Нейросеть работает лучше, чем простой метод наименьших квадратов, но производительность не так хороша, как при использовании корневого полинома или полиномиальной регрессии.

Преимущество подхода с корневым полиномом состоит в том, что он также инвариантен к ЭКСПОЗИЦИИ.

Colour correction

Когда мы решаем регрессию относительно одного уровня освещенности, результирующая матрица регрессии (которая обеспечивает цветокоррекцию) одинаково хорошо работает при изменении уровня освещенности. Напротив, нейросетевой подход обеспечивает плохую цветокоррекцию при изменении экспозиции.

Алгоритмы цветокоррекции насколько это возможно пытаются сопоставить отклики камеры с соответствующими координатами в цветовом пространстве, на которое ссылается человек.

Colour correction

Из статьи [11] приходим к выводу, что для цветокоррекции стоит использовать Root-Polynomial Regression models

- Изображение до и после применения colour correction:



Figure 1. These images are generated from David Foster's hyperspectral reflectance dataset [3] with Nikon D5100 camera responses and D65 illumination. While the left image (a) is representing RAW RGBs, the right one (b) demonstrates the colour corrected sRGB image.

Список литературы

- [1] A review for Tone-mapping Operators on Wide Dynamic Range Image - 2021 (<https://arxiv.org/pdf/2101.03003.pdf>)
- [2] A comparative review of tone-mapping algorithms for high dynamic range video - 2017 (https://www.repository.cam.ac.uk/bitstream/handle/1810/273688/eilertsen2017tmo_star.pdf?sequence=1)
- [3] Learning Tone Curves for Local Image Enhancement – 2022 (<https://ieeexplore.ieee.org/stamp/stamp.jsp?tp=&arnumber=9784427>)
- [4] Color Correction for Tone Mapping – 2009 (<https://www.cl.cam.ac.uk/~rkm38/pdfs/mantiuk09cctm.pdf>)
- [5] Deep Reverse Tone Mapping – 2017 (<http://www.cgg.cs.tsukuba.ac.jp/~endo/projects/DrTMO/>)
- [6] CURL: Neural curve layers for global image enhancement – 2020 (<https://arxiv.org/pdf/1911.13175.pdf>)
- [7] Deep bilateral learning for real-time image enhancement – 2017 (<https://groups.csail.mit.edu/graphics/hdrnet/data/hdrnet.pdf>)
- [8] Conditional sequential modulation for efficient global image retouching – 2020 (https://www.ecva.net/papers/eccv_2020/papers_ECCV/papers/123580664.pdf)
- [9] Image-to-image translation with conditional adversarial networks – 2018 (<https://arxiv.org/pdf/1611.07004.pdf>)
- [10] Zero-reference deep curve estimation for low-light image enhancement – 2020 (<https://arxiv.org/pdf/2001.06826.pdf>)
- [11] Comparison of regression methods and neural networks for colour correction - 2022(https://www.cl.cam.ac.uk/~rkm38/pdfs/kucuk2022_color_correction_cmp.pdf)
- [12] Deep Tone Mapping Operator for High Dynamic Range Images – 2019 (<https://arxiv.org/pdf/1908.04197.pdf>)
- [13] A Generative Adversarial Network for Tone mapping HDR images (https://www.researchgate.net/publication/321062066_A_Generative_Adversarial_Network_for_Tone_mapping_HDR_images)

Список литературы

- [14] H. Yeganeh and Z. Wang. Objective quality assessment of tone-mapped images. IEEE Transactions on Image Processing, 22(2):657–667, 2013
- [15] Unpaired Learning for High Dynamic Range Image Tone Mapping (https://openaccess.thecvf.com/content/ICCV2021/papers/Vinker_Unpaired_Learning_for_High_Dynamic_Range_Image_Tone_Mapping_ICCV_2021_paper.pdf)
- [16] F. Banterle, A. Artusi, K. Debattista, and A. Chalmers, Advanced High Dynamic Range Imaging: Theory and Practice, February 2011